

## Introduction à la statistique non-paramétrique

DM – 2020 –

**Exercice 1 :** Nous nous intéressons à la hauteur des arbres d'une même espèce de chênes présente dans une forêt.

- Nous supposons que la hauteur de ces chênes peut être modélisée par une variable aléatoire de loi normale  $\mathcal{N}(\mu, \sigma^2)$ . Nous disposons d'un échantillon de  $n = 8$  mesures  $x_1^n = (x_1, \dots, x_n)$  donnant une moyenne empirique  $\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = 20.31$  mètres.
  - Nous supposons que  $\sigma$  est connu et égal à 5.  
Donner un intervalle de confiance de taille 95%, puis de taille 99%, pour  $\mu$ .  
Proposer une procédure de test de  $H_0 : \mu = 16$  contre  $H_1 : \mu \neq 16$ .  
Procéder au test au niveau  $\alpha = 5\%$ , puis au niveau  $\alpha = 1\%$ .
  - Nous supposons maintenant que  $\sigma$  est inconnu.  
L'écart-type empirique mesuré  $\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$  est de 3.96.  
Proposer une procédure de test de  $H_0 : \mu = 16$  contre  $H_1 : \mu \neq 16$ , puis de  $H_0 : \mu \leq 16$  contre  $H_1 : \mu > 16$ .  
Déterminer dans chaque cas la  $p$ -valeur observée, et conclure si l'on teste au niveau  $\alpha = 5\%$ .
- Nous disposons maintenant de la série complète des données  $x_1^n$  (hauteurs en mètres)

19.37 21.12 24.84 18.10 15.61 24.05 14.17 25.26

et nous cherchons à tester si cet échantillon est distribué selon une loi normale. Pour cela nous supposons que  $x_1^n$  est issu d'un échantillon i.i.d.  $X_1^n$  de fonction de répartition  $F$  et l'on note  $\hat{F}_n$  la fonction de répartition empirique qui lui est associée. Nous notons  $N_{\mu, \sigma^2}$  la fonction de répartition d'une loi normale de paramètres  $\mu$  et  $\sigma^2$ . Nous cherchons à tester :

$$H_0 : F \in \mathcal{FN} \quad \text{contre} \quad H_1 : F \notin \mathcal{FN}$$

où  $\mathcal{FN} = \{G ; \exists (\mu, \sigma^2) \in (\mathbb{R} \times \mathbb{R}_+^*) \text{ tel que } G = N_{\mu, \sigma^2}\}$ .

Nous rappelons qu'ici  $\hat{\mu} = 20.31$  et  $\hat{\sigma} = 3.96$ , et nous utilisons comme statistique de test  $\Delta_n = \sup_{t \in \mathbb{R}} |\hat{F}_n(t) - N_{\hat{\mu}, \hat{\sigma}^2}(t)|$ .

- Rappeler la loi de cette statistique sous  $H_0$  et la région de rejet du test.
- Par une lecture graphique sur la Figure 1, où nous avons tracé  $\hat{F}_n$  et  $N_{\hat{\mu}, \hat{\sigma}^2}$ , déterminer la valeur de cette statistique.
- La loi sous  $H_0$  de cette statistique de test a été tabulée pour  $n = 8$ . En utilisant les quantiles donnés ci-dessous, conclure si l'on teste au niveau  $\alpha = 5\%$ .

	$q_{5\%}$	$q_{10\%}$	$q_{90\%}$	$q_{95\%}$
Statistique du test d'appartenance à la loi normale	0.14	0.15	0.27	0.29

- Donner une méthode d'estimation des quantiles de cette loi.




FIGURE 1 –  $\hat{F}_n$  (noir) et  $N_{\hat{\mu}, \hat{\sigma}^2}$  (rouge)

**Exercice 2 :** On a mesuré le rythme cardiaque (en nombre de battements par minute), avant et après un don du sang, de 8 sujets pris au hasard parmi les personnes se présentant spontanément à un centre de transfusion sanguine. On cherche à savoir si le rythme cardiaque est plus faible après qu'avant le don du sang c'est-à-dire que l'on cherche à procéder au test  $H_0$  : "le rythme cardiaque est le même avant et après le don du sang" contre  $H_1$  : "le rythme cardiaque est plus faible après le don du sang qu'avant le don du sang".

1. Nous disposons tout d'abord uniquement de la donnée suivante : 6 personnes parmi les 8 avaient un rythme cardiaque plus faible après le don du sang qu'avant le don du sang.
  - (a) Proposer une procédure de test
  - (b) Donner la  $p$ -valeur observée. Conclure si l'on teste au niveau  $\alpha = 5\%$ .
2. Nous disposons à présent des données suivantes :

Sujet	1	2	3	4	5	6	7	8
Mesure avant le don du sang	78	101	77	75	92	76	66	87
Mesure après le don du sang	84	80	67	72	79	77	64	80

TABLE 1 – Nombre de battements cardiaques par minute

- (a) Proposer une procédure de test.
- (b) A l'aide de la Table 2, donner la  $p$ -valeur observée. Conclure si l'on teste au niveau  $\alpha = 5\%$ .

$k$ $P[\tilde{h}_8 \leq k]$	0	1	2	3	4	5	6	7	8	9
	0.0039	0.0078	0.0117	0.0195	0.0273	0.0390	0.0547	0.0743	0.0978	0.1251
$k$ $P[\tilde{h}_8 \leq k]$	10	11	12	13	14	15	16	17	18	19
	0.1563	0.1915	0.2306	0.2736	0.3204	0.3711	0.4220	0.4727	0.5274	0.5783
$k$ $P[\tilde{h}_8 \leq k]$	20	21	22	23	24	25	26	27	28	29
	0.6290	0.6797	0.7265	0.7695	0.8087	0.8438	0.8751	0.9024	0.9259	0.9454
$k$ $P[\tilde{h}_8 \leq k]$	30	31	32	33	34	35	36			
	0.9610	0.9728	0.9805	0.9883	0.9922	0.9961	1.0000			

TABLE 2 – Loi de  $\tilde{h}_8 := \sum_{j=1}^8 jY_j$ , où  $Y_1, \dots, Y_8 \stackrel{iid}{\sim} Be(\frac{1}{2})$